

Artificial Bee Colony アルゴリズムによる サポートベクターマシンのハイパーパラメータ 最適化

2131007 安達 拓真

千葉工業大学 情報科学部 情報工学科 4 年 山口研究室


2024 年 9 月 3 日

はじめに

- 機械学習のハイパーパラメータを自動で調整する研究が行われている
- 先行研究として, Artificial Bee Colony アルゴリズム (ABC) を用いて, サポートベクターマシン (SVM) のハイパーパラメータ最適化と特徴選択を行った研究がある
- 本研究では, 先行研究で最適化対象ではなかったカーネル関数をハイパーパラメータとして扱う手法を提案する

サポートベクターマシン (SVM)

- 1995 年に C.Cortes らが提案した機械学習アルゴリズム¹
- 非線形データを高次元空間に写像し、線形分離可能にする
- データを分類する最適な境界線 (超平面) を探す



¹Cortes, C. and Vapnik, V. Support-vector networks, Machine Learning, Vol.20, No.3, pp.273-297, 1995.

Artificial Bee Colony(ABC) アルゴリズム

- 蜂の採餌行動に着目した最適化アルゴリズム²
- 働き蜂、追従蜂、偵察蜂の三種類の蜂によって各食物源の探索を行い、最適解を求める
- ABC 自体の設定パラメータは少ない

²Karaboga, Dervis. An idea based on honey bee swarm for numerical optimization. Vol. 200. Technical report-tr06, Erciyes university, engineering faculty, computer engineering department, 2005.

先行研究³における SVM のハイパーパラメータ最適化

- カーネル関数を RBF カーネルに固定
- ABC アルゴリズムを使用
- 最適化したハイパーパラメータ
 - ▶ SVM の C
 - ▶ ガウスカーネルの γ

³近藤 久, 浅沼 由馬 “人工蜂コロニーアルゴリズムによるランダムフォレストとサポートベクトルマシンのハイパーパラメータ最適化と特徴選択”, 人工知能学会論文誌, vol34-2, pp.1-11, 2019.

問題点

- カーネル関数を RBF カーネルに固定している
 - ▶ SVM には RBF カーネル以外にも様々なカーネル関数が適用できる
 - ▶ カーネル関数によってハイパーパラメータが異なる
- ハイパーパラメータ空間の探索範囲が限定的

提案手法

- 以下の4つのカーネル関数とそのハイパーパラメータも最適化対象とする

線形カーネル: $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \cdot \mathbf{x}_j$

RBF カーネル: $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$

シグモイドカーネル: $K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\gamma \mathbf{x}_i^T \cdot \mathbf{x}_j + \text{coef0})$

多項式カーネル: $K(\mathbf{x}_i, \mathbf{x}_j) = (\gamma \mathbf{x}_i^T \cdot \mathbf{x}_j + \text{coef0})^d$

カーネル関数を持つハイパーパラメータの扱い

- カーネル関数によってハイパーパラメータの数は異なる
- 同じ性質のパラメータが存在することに着目
 - ▶ 4つのカーネル関数のパラメータの合計は6個
 - ▶ 性質ごとに分けると3個
- 他のカーネル関数で使用するパラメータの値をそのまま使用
 - ▶ ランダム性により解の多様性が生まれる

カーネル関数を持つハイパーパラメータの扱い

- ABC における解表現は以下の 5 次元で表す

解表現：(カーネル関数, C , γ , coef0, d)

- カーネル関数によって異なるハイパーパラメータはカーネル関数の値によって活性, 非活性となる
- カーネル関数の更新はランダムに選ばれた個体とのルーレット選択

$$P = \frac{\text{fit}(\boldsymbol{x}_j)}{\text{fit}(\boldsymbol{x}_i) + \text{fit}(\boldsymbol{x}_j)}$$

i : 更新個体 j : ランダムに選ばれた値

実験

- 侵入検知問題である KDD'99 データセットを，デフォルトパラメータ，既存手法，提案手法で解く
- 既存手法，提案手法は 10 回ずつ実行し，平均値をとる
- データセットはランダムに 10%抽出した物を 3 つ使用する
 - ▶ 学習セット：SVM の学習に使用
 - ▶ 検証セット：SVM の評価に使用
 - ▶ テストセット：最終的に得られた最良解の評価に使用

実験パラメータ

Table: ABC の実験パラメータ

パラメータ	値
コロニーサイズ	20
LIMIT	100
サイクル数	500

Table: SVM の実験パラメータ

パラメータ	値
kernel	[linear, RBF, sigmoid, poly]
C	$[10^{-6}, 35000]$
γ	$[10^{-6}, 32]$
coef0	[0, 10]
d	[1, 3]

実験結果 (分類精度と実行時間)

- 提案手法はデフォルトパラメータ, 既存手法よりも分類精度が高くなった.
- 実行時間は既存手法よりも長くなった.

Table: 分類精度と実行時間

	線形	RBF	シグモイド	多項式	既存手法	提案手法
分類精度 [%]	99.68	99.78	96.12	99.76	99.88	99.91
実行時間 [h]	-	-	-	-	11.8	15.5

実験結果 (評価指標)

- 提案手法では TP, TN が向上し, FP, FN は減少したため, 検知率が向上し, 誤警報率は減少した
 - ▶ 侵入検知問題におけるモデルの性能が向上した

Table: 混同行列の値

	先行研究	提案手法
TP	39602.4	39609.7
TN	9743.8	9748.9
FP	22.2	17.1
FN	33.6	26.3

Table: モデルの評価指標

	先行研究	提案手法
検知率 [%]	99.91	99.93
誤警報率 [%]	0.23	0.17
適合率 [%]	99.94	99.96
F 値 [%]	99.93	99.95

考察

- 提案手法で実行時間が長くなってしまった原因
 - ▶ カーネル関数をハイパーパラメータとして扱い探索範囲を広げたこと
- 既存手法では RBF カーネルのみを使用
- RBF カーネルは汎用性が高く，他のカーネル関数に比べて学習時間が短い傾向にある
 - ▶ RBF カーネル以外のカーネル関数の個体の評価に時間がかかった可能性

おわりに

- カーネル関数もハイパーパラメータとして扱い，SVM のハイパーパラメータを最適化する手法を提案
- 提案手法は先行研究よりも分類精度が高くなったが，実行時間は長くなった
- 様々なデータセットで提案手法の汎用性を検証する必要がある